

IBMEC – Instituto Brasileiro de Mercado de Capitais
Extração e Preparação de Dados (IBM8915)
Professor: Luís Aramis

Diretrizes do Trabalho Final (AC)
Construção de Pipeline de ETL Orquestrado e Produto de IA

1 Objetivo do Projeto

O objetivo deste trabalho final é consolidar os conhecimentos adquiridos na disciplina. Cada aluno (ou dupla, conforme acordado) deverá projetar, desenvolver e apresentar um fluxo completo de engenharia de dados. Os projetos devem abranger a extração de dados brutos de uma fonte de livre escolha, a aplicação de transformações robustas de limpeza baseadas na arquitetura medalhão usando `scikit-learn`, a orquestração periódica do fluxo via **Apache Airflow**, a geração de previsões através de um modelo de Inteligência Artificial e a exibição em um dashboard analítico.

2 Requisitos Técnicos Obrigatórios

Os projetos serão avaliados conforme os seguintes componentes arquiteturais:

2.1 Escolha e Extração do Dataset (Camada Bronze)

- Escolha livre de um conjunto de dados do mundo real (ex: Kaggle, APIs públicas, portais governamentais).
- Os dados em seu estado bruto original devem ser extraídos e armazenados na camada **Bronze** (sem alterações) para servir de histórico auditável.

2.2 Pipeline de Limpeza e Preparação (Camada Silver)

Os alunos deverão implementar no mínimo três métodos de limpeza estudados ao longo do semestre de forma estruturada:

- **Tratamento de Dados Ausentes:** Imputação inteligente (univariada ou multivariada como `KNNImputer`).
- **Deteção de Outliers e Anomalias:** Métodos estatísticos (IQR/Z-Score) ou algorítmicos (`IsolationForest`).
- **Engenharia de Variáveis (Feature Engineering):** Codificação de texto/categóricas (`OneHotEncoder`, `TargetEncoder`) e escalonamento de grandezas (`StandardScaler`, `MinMaxScaler`).
- **Modularidade:** O preparo de dados **deve** ser encapsulado na classe `Pipeline` do `scikit-learn` para garantir o isolamento estatístico e prevenir *Data Leakage* (vazamento de dados) entre treino e teste.

2.3 Armazenamento e Consumo (Camada Gold)

- Os dados limpos e as variáveis de engenharia finais devem ser persistidos na camada **Gold**.
- A tabela da camada Gold servirá como base única de consumo para a IA e para a ferramenta de inteligência de negócios.

2.4 Produto de IA e Modelagem

- Treinar um modelo de Inteligência Artificial utilizando os dados finais da camada Gold.
- O modelo pode basear-se em **Machine Learning Clássico** (árvores, regressões), **Deep Learning** (redes MLP) ou **LLM** (enriquecimento de texto ou RAG).
- O produto de IA deve gerar previsões práticas que auxiliem na solução de um problema do dataset escolhido.

2.5 Orquestração (Apache Airflow)


- Construir uma DAG no Airflow com dependências claras conectando cada fase: Extração → Limpeza → Modelagem/Carga.
- Demonstrar tratamento de falhas (uso de retries) e logs legíveis no Webserver.

2.6 Visualização (Dashboard)

- Apresentar os resultados em um Dashboard interativo.
- Recomenda-se o uso do framework **Streamlit** (Python), embora ferramentas como Power BI, Tableau ou Apache Superset também sejam aceitas.

3 Arquitetura Conceitual do Pipeline

Abaixo está o diagrama do fluxo de dados obrigatório que o projeto deve seguir de ponta a ponta:



4 Critérios de Avaliação

A nota final do projeto (AC) considerará a seguinte distribuição de pesos:

Componente Avaliado	Peso
Orquestração e Robustez da DAG (Airflow)	25%
Qualidade e Modularidade do Pipeline de Limpeza (Sklearn)	25%
Integração e Desempenho do Modelo de IA	20%
Clareza e Interatividade do Dashboard de Negócio	15%
Apresentação Oral e Qualidade do Pitch de Solução	15%