

IBMEC – Instituto Brasileiro de Mercado de Capitais
Curso de Ciência de Dados & Inteligência Artificial

Relatório do Projeto Prático Final (AC)
Pipeline de ETL e Produto de IA: [Nome do Seu Projeto]

Alunos (Dupla ou Individual):

[Nome do Aluno 1 – Matrícula]

[Nome do Aluno 2 – Matrícula]

Disciplina: Extração e Preparação de Dados (IBM8915)
Professor: Luís Aramis

Rio de Janeiro, 2026

Índice

1	Introdução e Escolha do Dataset	2
1.1	Especificação e Saúde das Variáveis	2
2	Pipeline de ETL e Arquitetura Medalhão	2
2.1	Camada Bronze (Raw Data)	2
2.2	Camada Silver (Limpeza e scikit-learn)	3
2.3	Camada Gold (Consumo)	3
2.4	Linhagem Visual do Fluxo de Dados	4
3	Orquestração e Resiliência (Apache Airflow)	5
4	Produto de IA e Modelagem	5
5	Dashboard Analítico	7
6	Conclusão	7

1 Introdução e Escolha do Dataset

A etapa inicial de qualquer projeto de Ciência de Dados e Engenharia de Dados consiste na seleção e na compreensão do conjunto de dados (*dataset*) a ser explorado. Nesta seção, o grupo deve apresentar de forma contextualizada a origem da base de dados escolhida (por exemplo, repositório Kaggle, portais governamentais de dados abertos como o Brasil.IO, ou APIs proprietárias). A introdução deve descrever formalmente o cenário de negócios ou o domínio científico do dataset, destacando o problema prático que se pretende resolver por meio da modelagem preditiva ou da análise descritiva. É essencial detalhar a relevância desse problema e como a tomada de decisão orientada a dados (*data-driven*) agregará valor à organização ou ao contexto em estudo.

1.1 Especificação e Saúde das Variáveis

Após a contextualização do problema de negócio, os alunos devem documentar a estrutura física do dataset bruto coletado. Esta etapa serve como um diagnóstico de saúde de dados e dicionário de variáveis inicial. Deve-se listar a volumetria total da base (número total de linhas e colunas) e classificar cada uma das variáveis quanto ao seu tipo estatístico e de armazenamento (ex: categórica nominal, categórica ordinal, numérica discreta, numérica contínua, datetime, strings textuais não estruturadas). Adicionalmente, o grupo deve mapear o percentual inicial de registros ausentes (*missing values*) e identificar quais colunas necessitam obrigatoriamente de tratamento na Silver, fornecendo uma base lógica para o pipeline que será detalhado a seguir.

2 Pipeline de ETL e Arquitetura Medalhão

A engenharia de dados moderna adota frameworks estruturados para garantir a qualidade, auditabilidade e escalabilidade dos pipelines. Neste projeto, os alunos devem aplicar os conceitos da **Arquitetura Medalhão**, organizando o fluxo de dados em três camadas de refinamento progressivo: Bronze, Silver e Gold. Essa divisão lógica garante que as transformações de limpeza e enriquecimento ocorram em etapas isoladas, permitindo a rastreabilidade (*data lineage*) e o reprocessamento de dados históricos em produção de maneira segura.

2.1 Camada Bronze (Raw Data)

A camada Bronze é a porta de entrada do pipeline. Nela, os dados extraídos das fontes de origem são armazenados exatamente no mesmo formato e estado estrutural em que foram coletados (arquivos CSV brutos, respostas JSON de APIs ou tabelas de staging de bancos relacionais). O grupo deve explicar como configurou o script de ingestão para descarregar esses arquivos no diretório de destino. A premissa fundamental da camada Bronze é a **imutabilidade**: nenhuma transformação, alteração de tipo ou remoção de dados nulos deve ocorrer nesta fase. Ela atua como um repositório histórico permanente que protege o pipeline contra alterações destrutivas nas fontes de origem.

2.2 Camada Silver (Limpeza e scikit-learn)

A camada Silver representa a fase de higienização, padronização e enriquecimento estatístico. É o centro das transformações de dados (*Data Wrangling*). Nesta seção, os alunos devem detalhar a aplicação dos métodos de tratamento vistos ao longo do semestre. Obrigatoriamente, o grupo deve aplicar e descrever pelo menos três dos seguintes tópicos:

- **Tratamento de Dados Ausentes:** Justificar a escolha da estratégia de imputação. Recomenda-se comparar a imputação simples (mediana/moda) com métodos multivariados avançados, como o algoritmo `KNNImputer` (que calcula a distância euclidiana para estimar valores faltantes com base em vizinhos) ou `IterativeImputer`.
- **Tratamento de Outliers:** Documentar o impacto das anomalias no dataset. Detalhar a estratégia de corte estatístico (IQR ou Z-Score) ou a aplicação de algoritmos de Machine Learning não supervisionado para detecção de outliers multivariados, como o `IsolationForest` do Scikit-Learn.
- **Engenharia de Variáveis (Feature Engineering):** Explicar como os dados categóricos foram codificados (`OneHotEncoder` para nominais de baixa cardinalidade, ou `TargetEncoder` para categorias complexas) e a normalização de variáveis numéricas (`StandardScaler` ou `MinMaxScaler`).

Para evitar o fenômeno catastrófico do **Data Leakage** (vazamento de dados estatísticos da base de teste para a base de treino), os alunos devem encadear sequencialmente todos os passos de tratamento utilizando a classe `Pipeline` do subpacote `sklearn.pipeline`. O grupo deve descrever como dividiu os dados em treino e teste antes da limpeza, aplicando o método `.fit()` exclusivamente na base de treino e o método `.transform()` na base de teste.

A Tabela 1 ilustra como o grupo deve documentar a qualidade de dados inicial e a respectiva ação de tratamento na camada Silver, ajustada perfeitamente à largura útil da página.

Tabela 1: Exemplo de Documentação de Data Quality e Ações de Limpeza

Variável	Tipo Original	Dados Ausentes (%)	Ação de Limpeza (Silver)
Idade	float64	17,2%	Imputação por <code>KNNImputer</code> ($k = 5$)
Salário Anual	float64	5,4%	Imputação por Mediana + <code>StandardScaler</code>
Cidade	object	0,0%	Agrupamento de categorias raras + OHE
Score Crédito	int64	0,0%	Detecção de Outliers via <code>IsolationForest</code>

2.3 Camada Gold (Consumo)

A camada Gold é o destino final do pipeline de engenharia de dados. Ela contém tabelas agregadas, enriquecidas com engenharia de features de negócio e completamente limpas, prontas para consumo de analistas de BI e modelos preditivos. O grupo deve especificar a estrutura da tabela final Gold, os tipos de dados resultantes das transformações e o formato físico em que a base foi persistida (ex: arquivos Parquet para otimização de consultas colunares ou tabelas indexadas de bancos relacionais).

2.4 Linhagem Visual do Fluxo de Dados

A Figura 1 apresenta o fluxo de transformação e consumo de dados projetado pelo grupo, redimensionado para se ajustar dentro das margens.




Figura 1: Diagrama de Linhagem do Pipeline de ETL

3 Orquestração e Resiliência (Apache Airflow)

Em ambientes de produção, os scripts de extração e tratamento não podem rodar de forma isolada ou depender de execuções manuais agendadas via cron local. Os alunos devem justificar a necessidade da utilização de um orquestrador de fluxos de trabalho profissional, como o **Apache Airflow**, para gerenciar a execução do pipeline de dados.

O grupo deve explicar em detalhes o design da DAG construída, definindo os papéis de cada tarefa (*tasks*) e os operadores do Airflow utilizados (ex: **BashOperator** para rodar comandos de terminal, **PythonOperator** para acionar os scripts de limpeza, ou **Sensors** para aguardar a chegada de arquivos no repositório de entrada).

É de extrema importância documentar como o grupo lidou com a **resiliência** (configuração de políticas de tentativas automáticas em caso de falhas de conexão de rede ou bancos) e o conceito de **idempotência** (garantir que rodar a DAG múltiplas vezes sobre um mesmo período de dados substitua e atualize a camada final de forma correta, sem duplicar dados históricos ou corromper a base analítica).

4 Produto de IA e Modelagem

O valor de um pipeline de dados robusto reside na qualidade dos produtos analíticos gerados no fim do fluxo. Nesta seção, os alunos devem especificar a modelagem inteligente desenvolvida com base na massa de dados polida e enriquecida da camada Gold. O grupo deve classificar e detalhar a aplicação estatística escolhida:

- **Machine Learning Clássico:** Modelos de classificação ou regressão baseados no Scikit-Learn (ex: Árvores de Decisão, Random Forests, Regressões Logísticas), discutindo a seleção de parâmetros e a justificativa de escolha do modelo.
- **Deep Learning:** Uso de redes multicamadas profundas (MLPs) e a discussão conceitual de como o pré-processamento de escala de features (Standardization) foi crucial para permitir que os gradientes de erro do backpropagation convergissem e evitassem problemas de saturação.
- **Large Language Models (LLM):** Integração de modelos de linguagem para dados não estruturados (ex: análise de sentimento automatizada de textos livres da Bronze, sumarização, ou construção de bases vetoriais de embeddings para arquitetura RAG).

O grupo deve exibir métricas de performance adequadas para avaliar o modelo, discutindo como a qualidade das transformações da camada Silver impactou diretamente na performance do produto de IA final.

Como exemplo de entrega, a Tabela 2 compara os resultados obtidos pelo modelo aplicando ou não o pipeline de ETL robusto, evidenciando o impacto da limpeza de dados na IA.

Tabela 2: Comparação de Performance do Modelo Conforme Tratamento de Dados

Métrica de Avaliação	Sem ETL (Dados Crus)	Com ETL Robust (Camada Gold)
Acurácia (Accuracy)	68,4%	87,9%
Precisão (Precision)	62,1%	85,3%
F1-Score	65,0%	86,5%
Área sob Curva ROC (AUC)	0,72	0,91

A Figura 2 ilustra a matriz de confusão gerada para o conjunto de testes (20%) do modelo preditivo de aprovação de crédito, ajustada ao tamanho do texto interno.

		Classe Predita	
		Negativo	Positivo
Classe Real	Pos	Falso Negativo 15	Verdadeiro Positivo 81
	Neg	Verdadeiro Negativo 142	Falso Positivo 12
		Neg	Pos

Figura 2: Matriz de Confusão do Modelo Preditivo (Gold Data)

5 Dashboard Analítico

A visualização de dados serve como a vitrine do trabalho de engenharia e ciência de dados. A modelagem estatística de nada serve se os tomadores de decisão corporativos não conseguirem interagir com os resultados obtidos. Nesta seção, os alunos devem descrever e justificar a arquitetura do Dashboard analítico construído.

Devem demonstrar de que forma o painel consome diretamente as tabelas prontas da camada **Gold** para alimentar seus gráficos e de que maneira as previsões geradas pela Inteligência Artificial na fase anterior são exibidas de forma clara e intuitiva na tela. O grupo deve colar capturas de tela do dashboard operando em ambiente real, detalhando os filtros interativos de visualização rápida e os principais Indicadores-Chave de Performance (KPIs) criados.

A Figura 3 esboça a arquitetura visual recomendada para o dashboard em Streamlit, exibindo os principais indicadores na parte superior e as previsões na área principal.




Figura 3: Layout Sugerido para o Dashboard no Streamlit

6 Conclusão

A conclusão do relatório deve amarrar de forma integrada o ciclo de vida completo do dado percorrido pelo grupo. É o momento em que os alunos discutem as lições aprendidas, as maiores dificuldades técnicas encontradas (ex: instabilidade na extração de APIs, vazamento de dados que exigiu refatoração com Scikit-Learn ou latência de consulta do dashboard) e como a qualidade final da extração e da preparação de dados impactou diretamente nos resultados analíticos e preditivos. O grupo deve demonstrar compreensão clara do lema da engenharia de software aplicado a dados: a qualidade da inteligência artificial de consumo é diretamente proporcional à qualidade do ETL que a alimenta.